Instituto Tecnológico y de Estudios Superiores de Monterrey

Inteligencia artificial avanzada para la ciencia de datos

Reto: Privacidad y seguridad de los datos

Análisis de seguridad y logs de acceso

Facundo Bautista Barbera
A01066843

11 de octubre de 2026

Parte I.
Investigación individual

1. Investigación

Para esta parte investigué el artículo de Barton et al. (2025), que analiza la propiedad y la privacidad de los datos en la industria lechera. Lo elegí porque su contexto es muy parecido al nuestro: un establo lechero donde los datos se generan con sensores y sistemas automatizados, como los robots de ordeño del CAETEC. El artículo es el resultado de discusiones entre académicos, consultores, desarrolladores de tecnología y representantes de la industria, realizadas entre junio y diciembre de 2024 (Barton et al., 2025).

El primer hallazgo importante es que se creó un consenso en que los datos generados en una granja pertenecen al productor. Sin embargo, los autores señalan que esa propiedad se pierde en la práctica cuando los datos pasan a terceros, porque deja de ser claro quién es el dueño de los datos ya procesados y para qué se usan. Los productores suelen aceptar los términos de uso de las tecnologías sin entender sus implicaciones, por lo que pierden el control de su información sin darse cuenta (Barton et al., 2025).

Para evitarlo, el artículo recomienda que cualquier uso de los datos tenga un permiso explícito y por escrito, y que se explique claramente a dónde va la información. También propone separar los datos en tres niveles:

- **Datos crudos:** le pertenecen al productor.
- **Datos intermedios:** resultan de un primer procesamiento.

- **Datos procesados:** como análisis y modelos.

Cada nivel debe tener sus propias reglas para evitar usos no autorizados. Además, los autores sugieren acuerdos cortos y fáciles de leer que definan los derechos de uso, y ponen como ejemplo plataformas como JOIN DATA y DJUSTCONNECT, donde los datos solo se comparten con permiso. En cuanto a la seguridad, recomiendan transferencias seguras y restringir el acceso a los datos (Barton et al., 2025).

Estas recomendaciones aplican directamente a nuestro proyecto. Los datos que generan los robots DeLaval VMS pertenecen al CAETEC, y nosotros solo los usamos porque nos los compartieron para el reto. Por eso, el proceso que definimos como equipo pide el permiso por escrito de quienes nos compartieron los datos, guarda los datos crudos en un bucket privado al que solo entran los seis integrantes y registra cada acceso con CloudTrail. Los tres niveles también nos sirven para decidir qué puede salir del bucket: los datos crudos nunca se suben al repositorio, mientras que los resultados agregados y los modelos sí se pueden compartir.

Por último, el artículo tiene una limitación importante para nuestro caso: se enfoca en Estados Unidos, Europa e India, y no menciona México ni los sistemas de ordeño automático. Por eso lo complementamos con la Ley Federal de Protección de Datos Personales en Posesión de los Particulares, que aplica a los datos de personas que aparecen en los metadatos y en las fotos, pero no a los datos de las vacas.

Parte II.
Parte compartida del equipo

2. Naturaleza de los datos

Hay dos grupos de datos para el proyecto, uno perteneciente al “Problema de colas” y otro para la obtención del BCS por medio de imágenes. Los datos del problema de colas los generan los robots de ordeño DeLaval VMS del establo en CAETEC. Estos datos fueron compartidos por el profesor Benjamín Valdéz Aguirre y el profesor Eduardo Daniel Juárez Pineda por medio de una carpeta compartida en Google Drive. Para el dataset de fotos, las fotos fueron tomadas por estudiantes de los equipos del reto el 29 de septiembre de 2026, con dispositivos iPhone.

3. Análisis de anonimización

Los datos tabulares no contienen datos personales: No hay nombres de trabajadores, operadores ni clientes. Solo se identifican vacas y grupos de manejo. No obstante, es información interna del CAETEC y no deben hacerse públicos.

Conjunto	Contenido	Formato	Periodo
Ordeños por vaca	Hora, duración, producción, flujos por cuarto de ubre, conductividad, sangre, RCS, patadas, incompletos	36 CSV, uno por vaca	mar–jun 2025
Reporte reproductivo	Estado reproductivo y días desde parto, celo e inseminación	CSV	jul 2025
Inventario	Grupo, edad, concentrado consumido, fecha esperada de parto	CSV	jul 2025
Patadas	Registro de patadas por vaca	CSV	jul 2025
Histórico	Producción por sesión (vaca 6229) y paquete "Datos 2026 TEC-UAQ-UNAM"	XLSX, ZIP	hasta ene 2026
Condición corporal	BCS asignado por expertos	Hoja de Google	N/A(?)
Fotos	Imágenes de vacas, una carpeta por ID	JPG	sep 2026

Donde sí encontramos datos personales es en los metadatos de los archivos y en las fotos. En Google Drive, cada archivo muestra a su dueño con su matrícula o correo, y las fotos pueden guardar la ubicación GPS y el modelo del teléfono con el que se tomaron. Además, en algunas fotos podrían aparecer trabajadores o estudiantes. En la siguiente tabla se describe cada atributo, si identifica a una persona y qué se hará con él.

Atributo	¿Identifica a una persona?	Riesgo	Acción
ID de vaca	No	Información productiva y reproductiva del CAETEC	Se conserva, pero no se publica
Grupo y robot ("Grupo 6", "VMS 3")	No	Bajo	Se conserva
Fechas y horas de ordeño	No	Bajo	Se conserva
Dueño de los archivos en Drive (matrícula, correo)	Sí	Datos personales de estudiantes y profesores	No se copia a los datos ni al repositorio
Metadatos de las fotos (GPS, dispositivo)	Posible	Ubicación del establo y teléfono de un estudiante	Se eliminan antes de subir las fotos
Personas en las fotos	Posible	Imagen de trabajadores o estudiantes	Se recorta o se descarta la foto

4. Normativa e investigación

En México, la ley que regula la privacidad de la información es la Ley Federal de Protección de Datos Personales en Posesión de los Particulares, publicada el 20 de marzo de 2025. Esta ley solo protege datos de personas, por lo que aplica a los metadatos y a las fotos, pero no a los datos de las vacas. Para los datos de un establo no existe una ley específica, así que la industria se rige por acuerdos entre las partes y buenas prácticas. Cada integrante investigó una fuente distinta sobre estas prácticas:

4.1. Facundo Bautista Barbera

Fuentes

- Barton et al. (2025), Animals

Hallazgos principales

Los datos generados en el establo pertenecen al productor y solo se deben compartir con su permiso explícito y por escrito

4.2. Oswaldo Isaías Hernández Santes

Fuentes

- Norma ISO/IEC 20889:2018
- Pakrashi et al. (2023), Frontiers in Artificial Intelligence (CowMesh)

Hallazgos principales

Define la terminología y clasifica técnicas de desidentificación de datos según sus características, se basa en los principios de privacidad de la ISO/IEC 29100.

El paper CowMesh define una arquitectura para compartir datos de granjas lecheras donde cada productor conserva la propiedad de sus datos y todos acceden mediante un vocabulario común de datos (un diccionario de datos) y un solo protocolo de acceso, propone registrar cada acceso a los datos para documentarlos y que sea transparente el uso que se le da a estos mismos, además muestra los problemas que se tienen al manejar datos sin un estándar como pueden ser los archivos enviados por correo, versiones desactualizadas entre los miembros de equipo, features con diferentes nombres que pueden causar confusión entre las personas que controlan estos datos; esto sirve como base para definir un estándar con políticas y una bitácora de control de acceso para tener transparencia con los stakeholders y para evitar problemas con los datos dentro del equipo. Importante mencionar que CowMesh no se implementó y solo quedó como una propuesta pero es una buena base para implementarlo en nuestro proyecto.

4.3. Alfredo Alejandro Soto Herrera

Fuentes

- Norma ISO/IEC 25012:2008.
- Norma ISO/IEC 29100:2024.

Hallazgos principales

La primera norma nos permite definir un modelo de la calidad de datos, nos sirve para poder establecer requisitos, definir medidas y evaluaciones de los datos que poseemos. Así podemos definir de mejor manera cómo nos funcionan las imágenes que tenemos, además de los datos de lactancia de las vacas. Por otro lado, en la segunda norma se toma en cuenta el uso y privacidad de los datos, en donde se trata el consentimiento de las personas involucradas, elección, limitación, etc. Esto ayuda a escoger aquellas imágenes en donde llegan a salir personas en segundo plano.

4.4. Emiliano Camacho Ponce

Fuentes

- Norma ISO/IEC 27001:2022.
- Barton et al. (2025): Data Ownership and Privacy in Dairy Farming: Insights from U.S. and Global Perspectives.
- Kaur et al. (2022): Protecting farmers' data privacy and confidentiality: Recommendations and considerations.
- Wilgenbusch et al. (2022): Big data promises and obstacles: Agricultural data ownership and privacy.

Hallazgos principales

La ISO/IEC 27001:2022 permite proteger la información mediante controles de acceso, respaldos y gestión de riesgos. Las imágenes de las vacas pueden incluir elementos del entorno que revelen información sobre las instalaciones, la organización de la explotación o sus procedimientos de trabajo.

4.5. Iker Mejía Hernández

Fuentes

- Estándares ICAR (Section 2/11 & ISO 11784/11785).
- Boletines IDF (466/504).
- Regulaciones CANILEC/FEMELECHE (2022)

Hallazgos principales

Los transpondedores de 15 dígitos son identificadores universales trazables que requieren enmascaramiento obligatorio, mientras que los datos sanitarios (RCS/MDI) y curvas de producción están protegidos como secreto comercial del establo según códigos de la industria láctea.

4.6. Jorge Manuel Oyoqui Aguilera

Fuentes

- Cue et al. (2021), Animals: "Data governance in the dairy industry".
- Rocher et al. (2019), Nature Communications.
- NIST SP 800-53 Rev. 5 (2020), familias AC (control de acceso) y AU (auditoría).
- Sandhu et al. (1996), Computer: "Role-based access control models".
- Wilkinson et al. (2016), Scientific Data: principios FAIR.

Hallazgos principales

Cue et al. comenta que la gobernanza de los datos lecheros debe dejar en claro quién es el dueño de los datos, quién puede acceder a ellos y para qué, y describe cómo es que se ha manejado esto frente a leyes como la de GDPR y CCPA. Estas leyes solo aplican cuando se trata de datos personales y no de datos agrícolas, por lo que sirven como referencia de buenas prácticas, más no como obligación para nuestros datos de vacas.

Rocher et al. muestra que no basta con anonimizar los datos, pues con pocos atributos se puede reidentificar a casi cualquier persona incluso en datos incompletos. Es por eso que, además de quitar identificadores, conviene combinar medidas como no publicar los datos crudos, generalizar fechas y revisar las salidas antes de que las compartamos. Eso respalda nuestra práctica de nunca publicar los datos crudos y de limpiar los metadatos y las fotos.

NIST SP 800-53 funciona como una lista de controles para el proceso del equipo. La familia AC pide que cada persona tenga solo el acceso que necesita, lo que implica tener usuarios individuales con permisos mínimos. La familia AU pide registrar y poder revisar quién hizo qué, lo que corresponde al registro de CloudTrail y a la bitácora de autorizaciones.

Sandhu et al. propone que se den permisos por rol y no por persona, lo que justifica tener que definir roles claros en el equipo.

Finalmente, Wilkinson et al. (FAIR) recomienda que los datos deben estar bien descritos y que el acceso a dichos datos debe exigir autenticación y autorización, lo que se cubre con la hoja de descripción de los datos, el usuario individual con doble factor y con la bitácora.

4.7. Prácticas adoptadas

Con base en estas investigaciones, el equipo decidió adoptar cuatro prácticas: contar con el permiso por escrito de quienes nos compartieron los datos, restringir el acceso a personas identificadas, registrar cada acceso a los datos y nunca publicar los datos crudos.

5. Proceso de manejo de los datos

Al revisar los datos, encontramos que la forma en la que se comparten actualmente no es segura. Las fotos están compartidas con la opción "cualquier usuario de Internet con el enlace puede editar" y, además, con una cuenta personal de Gmail. Los archivos CSV los puede abrir cualquier persona del Tec que tenga el enlace. Por esta razón, definimos el siguiente proceso para trabajar con los datos.

Los datos se guardarán en un bucket privado de Amazon S3 en la región de México, cifrado y con el acceso público bloqueado. No se guardarán en el repositorio, en drives personales, en chats ni en correos. Solo se podrá acceder desde redes de confianza, como la del Tec o redes domésticas con contraseña, y nunca desde redes públicas.

Solo los seis integrantes del equipo podrán ver los datos. Cada uno tendrá su propio usuario de AWS con autenticación de dos factores, y las credenciales no se comparten. Antes de recibir acceso, cada integrante deberá firmar el acuerdo de confidencialidad del anexo A.

Los datos solo se descargarán para procesarlos. En el repositorio únicamente se guardará el código y los resultados agregados, nunca los datos crudos. Al terminar el proyecto, los datos se borrarán del bucket y de cualquier copia local.

6. Registros de acceso y autorizaciones

Para saber quién y cuándo tuvo acceso a los datos, usaremos AWS CloudTrail. Este servicio registra cada vez que alguien descarga o sube un archivo al bucket, junto con el usuario, el archivo, la fecha y la hora. Al final del proyecto exportaremos estos registros y los compararemos con el proceso descrito en la sección anterior.

Referencias

Barton, R., Burchard, J., Cabrera, V. E., Cook, D., Cooley, W., Cue, R., Fadul, L., Mattison, J., & Saha, A. (2025). Data ownership and privacy in dairy farming: Insights from U.S. and global perspectives. *Animals*, *15*(4), 524. https://doi.org/10.3390/ani15040524