Instituto Tecnológico y de Estudios Superiores de Monterrey

Inteligencia artificial avanzada para la ciencia de datos

Reto: Privacidad y seguridad de los datos

Análisis de seguridad y logs de acceso

Jorge Manuel Oyoqui Aguilera
A01711783

11 de octubre de 2026

Parte I.
Investigación individual

1. Investigación

1.1. Resumen y suposiciones

Se nos proporcionaron los archivos de ordeño de 34 vacas (donde cada una tuvo 35 columnas, habiendo 7,249 registros en total del 01/03/2025 al 18/07/2025), identificadas a través de su ID numérico. La columna de Usuario estuvo vacía para cada dataset, de modo que no parecieran contener datos de personas, aunque sigue siendo información de un tercero (del socio formador y del CAETEC), de modo que más adelante propondré reglas de acceso, anonimización y de registro para el manejo de estos datos. Me gustaría aclarar que el socio formador aún no ha respondido algunas dudas que tuve al querer realizar este reporte con respecto a los datos, por lo que estaré marcando mis supuestos conforme a lo que sé de los datos y los actualizaré en la siguiente entrega.

Mis supuestos son:

1. Los datos son del CAETEC y se nos dieron únicamente para realizar el reto; aparte del equipo, solo los profesores, el socio y el personal del CAETEC puede acceder a los datos y nadie más.
2. Desconozco si existe algún acuerdo de confidencialidad o de términos de uso.

3. Asumo que los IDs de las vacas no se pueden ligar a personas, pero desconozco si permitiría identificar el establo.
4. Hay copias de los datos en un Drive del equipo con acceso por permisos; desconozco si el socio permite que tengamos dichas copias.
5. Asumo que podemos usar los datos para entrenar modelos de machine learning, más desconozco que otra restricciones tenemos (por ejemplo, el uso de IA).

1.2. Riesgos y marco normativo

Considero que el riesgo principal no son los datos personales, sino la confidencialidad comercial y la identificación del establo. Los datos que veo más sensibles son:

- ID de la vaca: podría permitir que se identifique el establo o cruzarse con otros sistemas.
- Fecha y hora de cada ordeño: revelaría las rutinas del establo.
- Producción, salud de la ubre y destino de la leche: es información comercial y sanitaria.
- Operador: aunque hoy se encuentra vacío, si se llenara sería un dato personal.

Barton et al. [1] y Cue et al. [2] dicen que los datos generados en la granja pertenecen al productor y que compartirlos requeriría de permisos explícitos y usos claros. Esas serán las bases de las reglas que propongo. Estoy asumiendo que todos los datos pertenecen al CAETEC y que el acuerdo entre el Tec y el socio formador es la fuente de nuestras obligaciones.

La Ley Federal de Protección de Datos Personales en Posesión de los Particulares (la cual fue publicada en el DOF el 20/03/2025 y entró en vigencia desde el 21/03/2025) exige que haya avisos de privacidad y consentimiento expreso o tácito, según el caso [3]. Protege a personas, así que solo aplicaría si los datos permitieran identificar a alguien (por ejemplo, a un operador). La uso como referencia. Padilla y Anguiano [4], la fuente mexicana más reciente que encontré, definen datos personales, consentimiento y disociación, y advierten que anonimizar no elimina el riesgo como tal (aunque aún me faltaría confirmar los artículos en el DOF). El GDPR y el CCPA también aplican solo a datos personales [2]. Para datos agrícolas, el Código de Conducta de la UE pide que haya un consentimiento explícito del titular para el acceso de terceros, anonimizar o seudonimizar y avisar de inmediato de cualquier brecha [5], aunque me gustaría aclarar que esto es voluntario [6]. Wiseman et al. [7] explican que la falta de claridad sobre propiedad, portabilidad y responsabilidad frena el intercambio de datos; por eso no asumo permisos implícitos.

1.3. Anonimización

Anonimizar solo reduce el riesgo, más no lo elimina. Rocher et al. [8] muestran que datos incompletos y anonimizados siguen siendo reidentificables, y De Montjoye et al. [9] que muy pocos puntos de lugar y hora bastan para identificar a una persona. Por analogía, fecha, hora y producción podrían identificar a una vaca o al establo. Sweeney [10] define el k-anonimato (cada registro debe ser indistinguible de al menos k-1 más según sus cuasi-identificadores); con solo 34 vacas, k sería pequeño. Por eso combino varias medidas:

- Seudonimizar los IDs (V01–V34), con la tabla de equivalencias aparte y de acceso restringido.
- Generalizar el tiempo: reportar por día o semana, no por hora exacta.
- Tamaño mínimo de grupo: no compartir estadísticas de grupos de menos de 5 vacas (aunque el umbral sería ajustable según lo que diga el socio).
- Campo Usuario: si llegara a contener nombres, quitarlo de cualquier salida.
- No publicar datos crudos en repositorios públicos ni en plataformas como Kaggle.
- Revisar tablas y gráficas antes de entregarlas, para detectar valores que identifiquen a una vaca o al establo.

1.4. Proceso, políticas y estándares

Esta propuesta debe ser aprobada por mi equipo y por el socio formador.

Roles

- El socio formador es el titular y autoriza la finalidad y las altas y bajas de acceso.
- Un responsable del equipo pide altas y bajas, mantiene la bitácora y revisa los accesos.
- Todos los integrantes somos analistas que leen los datos y ejecutan notebooks, sin compartir ni descargar datos sin autorización.

Reglas

1. Los datos se usan solo para el reto, salvo que haya autorización del socio para usarlos en algo más.
2. Solo las cuentas institucionales del equipo tienen rol de lector en la carpeta compartida, sin enlaces públicos (“cualquiera con el enlace”). Las altas y bajas las solicita el responsable y las autoriza el socio. Profesores, socio y personal del CAETEC tienen sus propios permisos como dueños o evaluadores.
3. Los datos se deben leer desde Colab o desde el Drive del socio; pero no se descargan a equipos personales ni se suben a repositorios públicos. Los resultados se guardan en una carpeta restringida del equipo, y las copias de datos crudos del Drive del equipo (supuesto 4) se eliminan.
4. Las únicas herramientas de terceros son Drive y Colab; no se cargan datos en otras (incluida la IA generativa) sin autorización escrita del socio.
5. Todo entregable aplica las medidas de anonimización.
6. Cada alta, baja, consulta relevante y modificación se anota en la bitácora cuando ocurre; el código se versiona en GitHub y los notebooks conservan su historial.
7. Los incidentes (datos compartidos por error, accesos no autorizados) se avisan al responsable en máximo 24 horas, quien avisa al socio; se documenta qué pasó y cómo se corrigió.
8. El responsable revisa quién tiene acceso cada una o dos semanas y al cierre del reto.

9. Al cierre se retiran los accesos y se borran las copias derivadas con datos crudos, salvo indicación del socio.

El proceso compartido del equipo (bucket privado de S3 con CloudTrail) aplica los mismos principios; aquí describo la versión basada en Drive y Colab porque es con lo que trabajamos hasta ahora.

Estos estándares sirven para validar las reglas:

Estándar	Qué pide	Reglas	Evidencia
NIST SP 800-53 Rev. 5 [11], familia AC	Acceso mínimo necesario	2, 3	Captura fechada de "Administrar acceso"
NIST SP 800-53 Rev. 5 [11], familia AU	Registrar y revisar quién hizo qué	6	Actividad de Drive, historial de Colab, commits
ISO/IEC 27002:2022 [12], controles 5.15, 5.18 y 8.15	Control de acceso, alta y baja de derechos y registro	2, 6, 8	Bitácora y revisiones de permisos
Control de acceso por roles, Sandhu et al. [13]	Permisos por rol, no por persona	2	Tabla de roles del equipo
Principios FAIR, Wilkinson et al. [14]	Datos bien descritos, acceso con autenticación y autorización	2, 6	Reporte de descripción de los datos y bitácora

1.5. Registros y autorizaciones

Las evidencias tendrán que obtenerse de herramientas que ya guarden su propio historial, no de una tabla armada al final, y no se podrá inventar ni falsificar ningún registro. Las evidencias que podemos recolectar son:

- Correo o mensaje del socio donde autorice el acceso y la finalidad, con fecha y, de ser posible, firma.
- Capturas fechadas de "Administrar acceso" de la carpeta compartida y de la del equipo, y de los permisos del notebook.
- Panel de "Actividad" de Drive de las carpetas del equipo (muestra quién hizo qué y cuándo) e historial de versiones del notebook de Colab.
- Repositorio de GitHub con commits, issues y pull requests, con los datos excluidos mediante .gitignore.
- Acta o documento firmado que apruebe estas políticas, con fecha e involucrados.
- Bitácora de acceso y cambios, abierta desde la semana 10 y con los accesos previos a esa fecha.

La carpeta del socio no la controlamos, así que solo podremos registrar la actividad de nuestras copias y salidas. Plantilla de la bitácora:

Fecha y hora	Persona	Acción	Recurso	Motivo	Evidencia
DD-MM-AAAA hh:mm	Nombre	Alta o baja de acceso, lectura o cambio de código	Carpeta o notebook	Por qué o para qué	Enlace, captura o commit

Referencias Bibliográficas

[1] Barton, R., Burchard, J., Cabrera, V. E., Cook, D., Cooley, W., Cue, R., Fadul, L., Mattison, J., & Saha, A. (2025). "Data ownership and privacy in dairy farming: Insights from U.S. and global perspectives. Animals, 15(4), 524". Recuperado de: https://www.mdpi.com/2076-2615/15/4/524

[2] Cue, R., Doornink, M., George, R., Griffiths, B., Jorgensen, M. W., Rogers, R., Saha, A., Taysom, K., Cabrera, V. E., Wangen, S. R., & Fadul-Pacheco, L. (2021). "Data governance in the dairy industry. Animals, 11(10), 2981". Recuperado de: https://www.mdpi.com/2076-2615/11/10/2981

[3] Garrigues. (S. F.). "México: nueva Ley Federal de Protección de Datos Personales en Posesión de los Particulares". https://www.garrigues.com/es_ES/noticia/mexico-nueva-ley-federal-proteccion-d

[4] Padilla, & Anguiano. (2026). "Una revisión sobre la obtención y el manejo de datos desde una perspectiva ética y legal. Sincronía". Recuperado de: https://revistasincronia.cucsh.udg.mx/index.php/sincronia/article/view/1131/1273

[5] Ryan, M., Atik, C., Rijswijk, K., Bogaardt, M.-J., Maes, E., & Deroo, E. (2024). "The future of agricultural data-sharing policy in Europe: Stakeholder insights on the EU Code of Conduct. Humanities and Social Sciences Communications". Recuperado de: https://www.nature.com/articles/s41599-024-03710-1

[6] van der Burg, S., Wiseman, L., & Krkeljas, J. (2021). "Trust in farm data sharing: Reflections on the EU code of conduct for agricultural data sharing. Ethics and Information Technology, 23(3)". Recuperado de: https://link.springer.com/article/10.1007/s10676-020-09543-1

[7] Wiseman, L., Sanderson, J., Zhang, A., & Jakku, E. (2019). "Farmers and their data: An examination of farmers' reluctance to share their data through the lens of the laws impacting smart farming. NJAS – Wageningen Journal of Life Sciences". Recuperado de: https://research-repository.griffith.edu.au/items/9032bad4-5362-4dbd-9c7e-3d2b6cbaa50f

[8] Rocher, L., Hendrickx, J. M., & de Montjoye, Y.-A. (2019). "Estimating the success of re-identifications in incomplete datasets using generative models. Nature Communications, 10(1)". Recuperado de: https://doi.org/10.1038/s41467-019-10933-3

[9] de Montjoye, Y.-A., Hidalgo, C. A., Verleysen, M., & Blondel, V. D. (2013). "Unique in the crowd: The privacy bounds of human mobility. Scientific Reports, 3(1)". Recuperado de: https://doi.org/10.1038/srep01376

[10] Sweeney, L. (2002). “k-anonymity: A model for protecting privacy. International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems, 10(5), 557–570”. Recuperado de: https://www.hks.harvard.edu/publications/k-anonymity-model-protecting-privacy

[11] National Institute of Standards and Technology. (2020). “Security and privacy controls for information systems and organizations (NIST Special Publication 800-53, Rev. 5). U.S. Department of Commerce”. Recuperado de: https://nvlpubs.nist.gov/nistpubs/SpecialPublications/NIST.SP.800-53r5.pdf

[12] Instituto Nacional de Normalización. (2022). “Seguridad de la información, ciberseguridad y protección de la privacidad — Controles de seguridad de la información (NCh-ISO/IEC 27002:2022)”. Recuperado de: https://www.trusttech.cl/docs/TRUSTTECH_NCh_27002_2022.pdf

[13] Sandhu, R. S., Coyne, E. J., Feinstein, H. L., & Youman, C. E. (1996). “Role-based access control models. Computer, 29(2), 38–47”.

[14] Wilkinson, M. D., Dumontier, M., Aalbersberg, I. J., et al. (2016). “The FAIR guiding principles for scientific data management and stewardship. Scientific Data, 3, Article 160018”. Recuperado de: https://doi.org/10.1038/sdata.2016.18

Parte II.
Parte compartida del equipo

2. Naturaleza de los datos

Hay dos grupos de datos para el proyecto, uno perteneciente al “Problema de colas” y otro para la obtención del BCS por medio de imágenes. Los datos del problema de colas los generan los robots de ordeño DeLaval VMS del establo en CAETEC. Estos datos fueron compartidos por el profesor Benjamín Valdéz Aguirre y el profesor Eduardo Daniel Juárez Pineda por medio de una carpeta compartida en Google Drive. Para el dataset de fotos, las fotos fueron tomadas por estudiantes de los equipos del reto el 29 de septiembre de 2026, con dispositivos iPhone.

3. Análisis de anonimización

Los datos tabulares no contienen datos personales: No hay nombres de trabajadores, operadores ni clientes. Solo se identifican vacas y grupos de manejo. No obstante, es información interna del CAETEC y no deben hacerse públicos.

Donde sí encontramos datos personales es en los metadatos de los archivos y en las fotos. En Google Drive, cada archivo muestra a su dueño con su matrícula o correo, y las fotos pueden guardar la ubicación GPS y el modelo del teléfono con el que se tomaron. Además, en algunas

Conjunto	Contenido	Formato	Periodo
Ordeños por vaca	Hora, duración, producción, flujos por cuarto de ubre, conductividad, sangre, RCS, patadas, incompletos	36 CSV, uno por vaca	mar–jun 2025
Reporte reproductivo	Estado reproductivo y días desde parto, celo e inseminación	CSV	jul 2025
Inventario	Grupo, edad, concentrado consumido, fecha esperada de parto	CSV	jul 2025
Patadas	Registro de patadas por vaca	CSV	jul 2025
Histórico	Producción por sesión (vaca 6229) y paquete "Datos 2026 TEC-UAQ-UNAM"	XLSX, ZIP	hasta ene 2026
Condición corporal	BCS asignado por expertos	Hoja de Google	N/A(?)
Fotos	Imágenes de vacas, una carpeta por ID	JPG	sep 2026

fotos podrían aparecer trabajadores o estudiantes. En la siguiente tabla se describe cada atributo, si identifica a una persona y qué se hará con él.

Atributo	¿Identifica a una persona?	Riesgo	Acción
ID de vaca	No	Información productiva y reproductiva del CAETEC	Se conserva, pero no se publica
Grupo y robot ("Grupo 6", "VMS 3")	No	Bajo	Se conserva
Fechas y horas de ordeño	No	Bajo	Se conserva
Dueño de los archivos en Drive (matrícula, correo)	Sí	Datos personales de estudiantes y profesores	No se copia a los datos ni al repositorio
Metadatos de las fotos (GPS, dispositivo)	Posible	Ubicación del establo y teléfono de un estudiante	Se eliminan antes de subir las fotos
Personas en las fotos	Posible	Imagen de trabajadores o estudiantes	Se recorta o se descarta la foto

4. Normativa e investigación

En México, la ley que regula la privacidad de la información es la Ley Federal de Protección de Datos Personales en Posesión de los Particulares, publicada el 20 de marzo de 2025. Esta ley solo protege datos de personas, por lo que aplica a los metadatos y a las fotos, pero no a los datos de las vacas. Para los datos de un establo no existe una ley específica, así que la industria se rige por acuerdos entre las partes y buenas prácticas. Cada integrante investigó una fuente distinta sobre estas prácticas:

4.1. Facundo Bautista Barbera

Fuentes

- Barton et al. (2025), Animals

Hallazgos principales

Los datos generados en el establo pertenecen al productor y solo se deben compartir con su permiso explícito y por escrito

4.2. Oswaldo Isaías Hernández Santes

Fuentes

- Norma ISO/IEC 20889:2018
- Pakrashi et al. (2023), Frontiers in Artificial Intelligence (CowMesh)

Hallazgos principales

Define la terminología y clasifica técnicas de desidentificación de datos según sus características, se basa en los principios de privacidad de la ISO/IEC 29100.

El paper CowMesh define una arquitectura para compartir datos de granjas lecheras donde cada productor conserva la propiedad de sus datos y todos acceden mediante un vocabulario común de datos (un diccionario de datos) y un solo protocolo de acceso, propone registrar cada acceso a los datos para documentarlos y que sea transparente el uso que se le da a estos mismos, además muestra los problemas que se tienen al manejar datos sin un estándar como pueden ser los archivos enviados por correo, versiones desactualizadas entre los miembros de equipo, features con diferentes nombres que pueden causar confusión entre las personas que controlan estos datos; esto sirve como base para definir un estándar con políticas y una bitácora de control de acceso para tener transparencia con los stakeholders y para evitar problemas con los datos dentro del equipo. Importante mencionar que CowMesh no se implementó y solo quedó como una propuesta pero es una buena base para implementarlo en nuestro proyecto.

4.3. Alfredo Alejandro Soto Herrera

Fuentes

- Norma ISO/IEC 25012:2008.
- Norma ISO/IEC 29100:2024.

Hallazgos principales

La primera norma nos permite definir un modelo de la calidad de datos, nos sirve para poder establecer requisitos, definir medidas y evaluaciones de los datos que poseemos. Así podemos definir de mejor manera cómo nos funcionan las imágenes que tenemos, además de los datos de lactancia de las vacas. Por otro lado, en la segunda norma se toma en cuenta el uso y privacidad de los datos, en donde se trata el consentimiento de las personas involucradas, elección, limitación, etc. Esto ayuda a escoger aquellas imágenes en donde llegan a salir personas en segundo plano.

4.4. Emiliano Camacho Ponce

Fuentes

- Norma ISO/IEC 27001:2022.
- Barton et al. (2025): Data Ownership and Privacy in Dairy Farming: Insights from U.S. and Global Perspectives.
- Kaur et al. (2022): Protecting farmers' data privacy and confidentiality: Recommendations and considerations.
- Wilgenbusch et al. (2022): Big data promises and obstacles: Agricultural data ownership and privacy.

Hallazgos principales

La ISO/IEC 27001:2022 permite proteger la información mediante controles de acceso, respaldos y gestión de riesgos. Las imágenes de las vacas pueden incluir elementos del entorno que revelen información sobre las instalaciones, la organización de la explotación o sus procedimientos de trabajo.

4.5. Iker Mejía Hernández

Fuentes

- Estándares ICAR (Section 2/11 & ISO 11784/11785).
- Boletines IDF (466/504).
- Regulaciones CANILEC/FEMELECHE (2022)

Hallazgos principales

Los transpondedores de 15 dígitos son identificadores universales trazables que requieren enmascaramiento obligatorio, mientras que los datos sanitarios (RCS/MDI) y curvas de producción están protegidos como secreto comercial del establo según códigos de la industria láctea.

4.6. Jorge Manuel Oyoqui Aguilera

Fuentes

- Cue et al. (2021), Animals: "Data governance in the dairy industry".
- Rocher et al. (2019), Nature Communications.
- NIST SP 800-53 Rev. 5 (2020), familias AC (control de acceso) y AU (auditoría).
- Sandhu et al. (1996), Computer: "Role-based access control models".
- Wilkinson et al. (2016), Scientific Data: principios FAIR.

Hallazgos principales

Cue et al. comenta que la gobernanza de los datos lecheros debe dejar en claro quién es el dueño de los datos, quién puede acceder a ellos y para qué, y describe cómo es que se ha manejado esto frente a leyes como la de GDPR y CCPA. Estas leyes solo aplican cuando se trata de datos personales y no de datos agrícolas, por lo que sirven como referencia de buenas prácticas, más no como obligación para nuestros datos de vacas.

Rocher et al. muestra que no basta con anonimizar los datos, pues con pocos atributos se puede reidentificar a casi cualquier persona incluso en datos incompletos. Es por eso que, además de quitar identificadores, conviene combinar medidas como no publicar los datos crudos, generalizar fechas y revisar las salidas antes de que las compartamos. Eso respalda nuestra práctica de nunca publicar los datos crudos y de limpiar los metadatos y las fotos.

NIST SP 800-53 funciona como una lista de controles para el proceso del equipo. La familia AC pide que cada persona tenga solo el acceso que necesita, lo que implica tener usuarios individuales con permisos mínimos. La familia AU pide registrar y poder revisar quién hizo qué, lo que corresponde al registro de CloudTrail y a la bitácora de autorizaciones.

Sandhu et al. propone que se den permisos por rol y no por persona, lo que justifica tener que definir roles claros en el equipo.

Finalmente, Wilkinson et al. (FAIR) recomienda que los datos deben estar bien descritos y que el acceso a dichos datos debe exigir autenticación y autorización, lo que se cubre con la hoja de descripción de los datos, el usuario individual con doble factor y con la bitácora.

4.7. Prácticas adoptadas

Con base en estas investigaciones, el equipo decidió adoptar cuatro prácticas: contar con el permiso por escrito de quienes nos compartieron los datos, restringir el acceso a personas identificadas, registrar cada acceso a los datos y nunca publicar los datos crudos.

5. Proceso de manejo de los datos

Al revisar los datos, encontramos que la forma en la que se comparten actualmente no es segura. Las fotos están compartidas con la opción "cualquier usuario de Internet con el enlace puede editar" y, además, con una cuenta personal de Gmail. Los archivos CSV los puede abrir cualquier persona del Tec que tenga el enlace. Por esta razón, definimos el siguiente proceso para trabajar con los datos.

Los datos se guardarán en un bucket privado de Amazon S3 en la región de México, cifrado y con el acceso público bloqueado. No se guardarán en el repositorio, en drives personales, en chats ni en correos. Solo se podrá acceder desde redes de confianza, como la del Tec o redes domésticas con contraseña, y nunca desde redes públicas.

Solo los seis integrantes del equipo podrán ver los datos. Cada uno tendrá su propio usuario de AWS con autenticación de dos factores, y las credenciales no se comparten. Antes de recibir acceso, cada integrante deberá firmar el acuerdo de confidencialidad del anexo A.

Los datos solo se descargarán para procesarlos. En el repositorio únicamente se guardará el código y los resultados agregados, nunca los datos crudos. Al terminar el proyecto, los datos se borrarán del bucket y de cualquier copia local.

6. Registros de acceso y autorizaciones

Para saber quién y cuándo tuvo acceso a los datos, usaremos AWS CloudTrail. Este servicio registra cada vez que alguien descarga o sube un archivo al bucket, junto con el usuario, el archivo, la fecha y la hora. Al final del proyecto exportaremos estos registros y los compararemos con el proceso descrito en la sección anterior.